

5. Makine Öğreniminin Türleri

Makine öğrenmesi yaklaşımları, öğrenme sistemi için mevcut olan "sinyal" veya "geri bildirim" in doğasına bağlı olarak geleneksel olarak üç geniş kategoriye ayrılır:

Makine öğrenmesi, bir öğrenme algoritmasının, veri yığını içinde öğrenme veri setini deneyimledikten sonra görevler üzerinde doğru bir şekilde performans gösterebilmesidir. Öğrenme örnekleri, genel olarak bilinmeyen bazı olasılık dağılımından (olayların alanını temsil eden kabul edilir) gelir ve makine öğrenmesi, bu alan hakkında yeni durumlarda yeterince doğru tahminler üretmesini sağlayan genel bir model oluşturmaktadır.

Makine öğrenmesi algoritmalarının hesaplamalı analizi ve performansları, hesaplamalı öğrenme teorisi olarak bilinen teorik bilgisayar biliminin bir dalıdır. Öğrenme setleri sonlu ve gelecek belirsiz olduğundan, öğrenme teorisi genellikle algoritmaların performansının garantisini vermez. Bunun yerine, performans üzerindeki olasılık sınırları oldukça yaygındır. Eğilim-varyans ayrışması, genelleme hatasını ölçmenin bir yoludur.

Genelleme bağlamında en iyi performans için, hipotezin karmaşıklığı, verilerin altında yatan fonksiyonun karmaşıklığıyla eşleşmelidir. Hipotez işlevden daha az karmaşıksa, model verileri altına yerleştirmiştir. Yanıt olarak modelin karmaşıklığı artarsa, öğrenme hatası azalır. Ancak hipotez çok karmaşıksa, model aşırı uyuma tabidir ve genelleme daha zayıf olacaktır.

Performans sınırlarına ek olarak, öğrenme kuramcıları öğrenmenin zaman karmaşıklığını ve fizibilitesini inceler. Hesaplamalı öğrenme teorisinde, bir hesaplama polinom zamanında yapılabiliyorsa uygulanabilir olarak kabul edilir. İki tür zaman karmaşıklığı sonucu vardır. Olumlu sonuçlar, polinom zamanında belirli bir fonksiyon sınıfının öğrenilebileceğini göstermektedir. Olumsuz sonuçlar, bazı sınıfların polinom zamanında öğrenilemeyeceğini göstermektedir.

Makine öğreniminde "Aşırı Uyum"

Makine öğreniminde, istatistiksel bir model, temelde yatan ilişki yerine rastgele hata veya gürültüyü tanımladığında "aşırı uyum" ortaya çıkar. Bir model aşırı derecede karmaşık olduğunda, eğitim veri türlerinin sayısına göre çok fazla parametrenin olması nedeniyle normal olarak aşırı uyum gözlemlenir. Model, aşırı uyumlu olan zayıf performans sergiliyor.

Modeli eğitmek için kullanılan kriterler, bir modelin etkinliğini değerlendirmek için kullanılan kriterlerle aynı olmadığından, aşırı uyum olasılığı oluşur.

Çok fazla veri kullanarak aşırı uydurma önlenabilir, küçük bir veri kümeniz olduğundan ve siz ondan öğrenmeye çalıştığınız için aşırı uydurma nispeten gerçekleşir. Ancak küçük bir veritabanınız varsa ve buna dayalı bir modelle gelmek zorunda kalırsanız. Böyle bir durumda çapraz doğrulama olarak bilinen bir teknik kullanabilirsiniz. Bu yöntemde veri kümesi, test ve eğitim veri kümeleri olmak üzere iki bölüme ayrılır, test veri kümesi yalnızca modeli test ederken, eğitim veri kümesinde veri noktaları modelle birlikte gelir.

Bu teknikte, bir modele genellikle eğitimin (eğitim veri seti) çalıştırıldığı bilinen bir veri kümesi ve modelin test edildiği bilinmeyen verilerden oluşan bir veri kümesi verilir. Çapraz doğrulama fikri, eğitim aşamasında modeli "test etmek" için bir veri kümesi tanımlamaktır.

Makine öğrenmesinin yapay zeka ile ilişkisi:

Bilimsel bir çaba olarak, makine öğrenmesi yapay zeka arayışından doğdu. Akademik bir disiplin olarak yapay zekanın (Artificial intelligence – AI) ilk günlerinde, bazı araştırmacılar makinelerin verilerden öğrenmesini istiyorlardı. Soruna çeşitli sembolik yöntemlerle ve daha sonra "sinir ağları" olarak adlandırılan yöntemle yaklaştırmaya çalıştılar; bunlar çoğunlukla algılayıcılar ve daha sonra genelleştirilmiş doğrusal istatistik modellerinin yeniden icadı olarak bulunan diğer modellerdi. Olasılıksal akıl yürütme, özellikle otomatik tıbbi tanıda da kullanılmıştır.

Yapay öğrenme ile makine öğrenimi arasındaki fark nedir?

DeneySEL verilere dayalı davranışlara göre algoritma tasarlama ve geliştirme, Makine Öğrenimi olarak bilinir. Yapay zeka, makine öğrenimine ek olarak bilgi sunumu, doğal dil işleme, planlama, robotik gibi diğer konuları da kapsar.

Mantıksal, bilgiye dayalı yaklaşıma artan vurgu, yapay zeka ve makine öğrenmesi arasında bir kaymaya neden oldu. Olasılıksal sistemler, veri toplama ve temsil etme ile ilgili teorik ve pratik problemlerle boğulmuştu. 1980'e gelindiğinde, uzman sistemler yapay zekaya hâkim olmuştu ve istatistikler kaybolmuştu. Yapay zeka içinde sembolik bilgiye dayalı öğrenme üzerine çalışmalar devam etmiş, bu da tümevarımsal mantık programlamaya yol açmıştır.

İstatistiksel araştırma çizgisi artık yapay zekâ alanının dışında, örüntü tanıma ve bilgi edinmede uygulanmaya başlamıştı. Yapay sinir ağları araştırması aynı zamanda yapay zeka ve bilgisayar bilimleri tarafından terk edilmişti. Bu çizgi de, Hopfield, Rumelhart ve Hinton da dahil olmak üzere diğer disiplinlerden araştırmacılar tarafından “bağlantıcılık” olarak AI alanının dışında devam etti. Başlıca başarıları 1980'lerin ortalarında geri yayılımın yeniden keşfedilmesiyle geldi.

Ayrı bir alan olarak yeniden düzenlenen makine öğrenmesi 1990'larda gelişmeye başladı. Alan, yapay zeka elde etmekten pratik nitelikteki çözülebilir problemlerle başa çıkmak için amacını değiştirdi. Odağı AI'dan miras aldığı sembolik yaklaşımlardan uzaklaşarak istatistik ve olasılık teorisinden ödünç alınan yöntem ve modellere kaydıldı. 2019 itibarıyla, birçok kaynak makine

öğrenmesinin Yapay Zeka'nın bir alt alanı olduğunu iddia etmeye devam ediyor. Yine de bazı uygulayıcılar, örneğin hem AI öğreten hem de sahada faaliyet gösteren bir şirket işleten Dr Daniel Hulme, makine öğrenmesi ve AI'nın ayrı olduğunu savunuyor.

Makine öğrenmesinin veri madenciliği ile ilişkisi:

Makine öğrenmesi ve veri madenciliği genellikle aynı yöntemleri kullanır ve önemli ölçüde örtüşür, ancak makine öğrenmesi öğrenme verilerinden öğrenilen öngörüye odaklanırken, veri madenciliği verilerde (önceden) bilinmeyen özelliklerin keşfine odaklanır (bu veritabanlarında bilgi keşfinin analiz basamağı). Veri madenciliği birçok makine öğrenme yöntemi kullanır, ancak farklı hedefleri vardır; Öte yandan, makine öğrenmesi aynı zamanda veri denetim yöntemlerini "denetimsiz öğrenme" veya öğrenme doğruluğunu geliştirmek için bir ön işleme adımı olarak kullanır. Makine öğrenmesinde, performans genellikle Bilinen bilgiyi yeniden üretirken, bilgi keşfi ve veri madenciliği için temel görev önceden bilinmeyen bilgilerin keşfidir. Bilinen bilgilere göre değerlendirildiğinde, bilgisiz (denetimsiz) bir yöntem diğer denetimli yöntemlerle kolayca daha iyi performans gösterirken, tipik bir veri madenciliği görevinde denetimli yöntemler öğrenme verilerinin bulunamaması nedeniyle kullanılamaz.

Makine öğrenmesinin optimizasyon ile ilişkisi:

Makine öğrenmesinin de optimizasyon ile yakın bağları vardır: birçok öğrenme problemi, bir öğrenme seti örneğindeki bazı kayıp işlevlerinin en aza indirilmesi olarak formüle edilmiştir. Kayıp fonksiyonları, eğitilmekte olan modelin tahminleri ile gerçek problem örnekleri arasındaki tutarsızlığı ifade eder (örneğin, sınıflandırmada, örneklerle bir etiket atamak ister ve modeller, bir dizi grubun önceden atanmış etiketlerini doğru şekilde tahmin etmek için eğitilir örnekler). İki alan arasındaki fark genelleme amacından kaynaklanmaktadır: **optimizasyon algoritmaları bir öğrenme setindeki kaybı en aza indirirken, makine öğrenmesi görünmeyen numunelerdeki kaybı en aza indirmekle ilgilidir. Parametrelerin hassasiyetinin belirlenmesinde optimizasyon algoritmaları, makine öğrenmesinde kritik rol oynakamaktadır.**

Makine öğrenmesinin istatistiklerle ilişkisi:

Makine öğrenmesi ve istatistikler, yöntemler açısından yakından ilişkili alanlardır, ancak temel amaçlarında farklıdır: **İstatistik, bir örneklemden analiz etmeye ya da yorumlamaya yönelik çıkarımlar elde ederken, makine öğrenmesi genelleştirilebilir tahmin modelleri bulur.**

Metodolojik prensiplerden teorik araçlara kadar makine öğrenmesi fikirleri istatistiklerde uzun bir geçmişe sahiptir. Ayrıca, veri bilimi terimi, genel alanı çağırmaq için bir yer tutucudur. İstatistiksel modelleme paradigmasını ayırt edilirse: veri modeli ve makine öğrenme algoritmaları aşağı yukarı, makine öğrenmesi yöntemlerinin benimsediği istatistiksel öğrenme birleşik bir alana yol açmıştır.

İstatistik ve Makine Öğrenimi verileri tanımlamak, analiz etmek ve modellemek için işlevler ve uygulamalar sağlar. Açıklayıcı veri analizi için tanımlayıcı istatistikleri, görselleştirmeleri ve

kümelemeyi kullanabilir, olasılık dağılımlarını verilere uydurabilir, Monte Carlo simülasyonları için rasgele sayılar üretebilir ve hipotez testleri gerçekleştirebilirsiniz. Regresyon ve sınıflandırma algoritmaları, Sınıflandırma ve Regresyon Öğrenici uygulamalarını kullanarak etkileşimli olarak verilerden çıkarımlar yapmanıza ve tahmine dayalı modeller oluşturmaya olanak tanır.

Çok boyutlu veri analizi ve özellik çıkarma için araç kutusu, değişkenleri en iyi tahmin gücüyle tanımlamanıza izin veren temel bileşen analizi (PCA), düzenleme, boyutsallık azaltma ve özellik seçme yöntemleri sağlar.

Araç kutusu, destek vektör makineleri (SVM'ler), artırılmış karar ağaçları, k-ortalamlar ve diğer kümeleme yöntemleri dahil olmak üzere denetimli, yarı denetimli ve denetimsiz makine öğrenimi algoritmaları sağlar. Kısmi bağımlılık çizimleri ve LIME gibi yorumlanabilirlik tekniklerini uygulayabilir ve gömülü dağıtım için otomatik olarak C/C++ kodu oluşturabilirsiniz. Birçok araç kutusu algoritması, bellekte saklanamayacak kadar büyük veri kümelerinde kullanılabilir.

Makine öğrenmesi ve matematik:

Faydalı sonuçlar elde etmek için, belirli genel makine öğrenimi ilkeleri ve bireysel algoritmaların iç işleyişi hakkında iyi matematiksel sezgilere ihtiyaç var. İyi bir matematik alt yapısı ile,

- Problem için **doğru algoritmalar** seçilir.
- **Parametre ayarları, doğrulama stratejileri** hakkında iyi seçimler yapılır.
- **Fazla veya yetersiz uyum** tanınır.
- **Yetersiz ya da belirsiz sonuçlar** giderilir.
- Sonuçlara uygun **güven ya da belirsizlik sınırları** konulur.
- **Kodlama algoritmalarında** daha iyi bir iş yapılırsa veya onlar daha karmaşık hale getirilir.

Makine öğreniminde hipotezler veya model oluşturma'nın üç aşaması:

- Model oluşturma
- Model testi
- Modeli uygulamak

Makine Öğrenimindeki farklı yaklaşımlar:

- Konsept ve Sınıflandırma Öğrenimi
- Sembolik vs İstatistiksel Öğrenme
- Endüktif Vs Analitik Öğrenme

Makine Öğreniminin iki tekniği şunlardır:

- Genetik Programlama
- Endüktif Öğrenme

Makine Öğrenimindeki farklı teknik türleri:

Makine öğrenmesi algoritmalarının türleri, yaklaşımlarına, girdikleri ve çıktıkları veri türlerine ve çözmeleri amaçlanan görev veya sorun türlerine göre farklılık gösterirler.

- Denetimli Öğrenme (Supervised Learning Algorithms)
- Denetimsiz Öğrenme (Unsupervised Learning Algorithms)
- Yarı denetimli Öğrenme
- Takviye Öğrenme
- Transdüksiyon
- Öğrenmeyi öğrenmek